

Resumen Inferencia Estadística

Introducción

Resumen de la materia de inferencia estadística de la Licenciatura en Tecnología Digital en la Universidad Torcuato Di Tella.

Contenido

- Resumen Inferencia Estadística
 - Introducción
 - Contenido
 - Esperanza
 - Varianza
 - Desvío Estándar
 - Covarianza
 - Correlación
 - Continuas
 - Distribución Normal
 - Función acumulada
 - Distribución Uniforme
 - Distribución Exponencial
 - Discretas
 - Distribución Bernoulli
 - Distribución Binomial
 - Distribución Poisson
 - Convergencia en Probabilidad
 - Propiedades
 - Estimación por LGN
 - Estimación Esperanza
 - Estimación Varianza
 - Estimación Proporción
 - Estimación de Probabilidad
 - Formulas Consistencia
 - Sesgo

- Asintóticamente Insesgado
- Error Estándar
- Error Cuadrático Medio
- Desigualdad de Chebyshev
- Desigualdad de Markov
- Momentos
 - Momentos de una variable aleatoria
 - Discreta
 - Continua
- Estimación por Máxima Verosimilitud (Likelihood)
 - Log-likelihood
- Intervalos de Confianza
 - Intervalo de Confianza para μ
 - T-Student

Esperanza

$$E(X) = \sum_{i=1}^n x_i F_x(x_i)$$

$$E(\bar{X}_n) = \frac{1}{n} \times \sum_{i=1}^n E(X_i)$$

Si X y Y son variables aleatorias con esperanza finita y $a, b, c \in \mathbb{R}$ son constantes entonces

- $E[c] = c$
- $E[cX] = cE[X]$
- $E[X + Y] = E[X] + E[Y]$
- Si $X \geq 0$ entonces $E[X] \geq 0$
- Si $X \leq Y$ entonces $E[X] \leq E[Y]$
- Si X está delimitada por dos números reales, a y b , esto es $a < X < b$ entonces también lo está su media, es decir, $a < E[X] < b$
- Si $Y = a + bX$, entonces $E[Y] = E[a + bX] = a + bE[X]$
- Si X y Y son variables aleatorias independientes entonces $E[XY] = E[X]E[Y]$

Varianza

$$\text{Var}[X] = E[X^2] - E[X]^2 \implies E[X^2] = \text{Var}[X] + E[X]^2$$

Sean X y Y dos variables aleatorias con varianza finita y $a \in \mathbb{R}$

- $\text{Var}(X) \geq 0$
- $\text{Var}(a) = 0$
- $\text{Var}(aX) = a^2 \text{Var}(X)$
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$, donde $\text{Cov}(X, Y)$ denota la covarianza de X e Y
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ si X y Y son variables aleatorias independientes.
- $\text{Var}(Y) = \text{E}(\text{Var}(Y|X)) + \text{Var}(\text{E}(Y|X))$ cálculo de la Varianza por Pitágoras, dónde $Y|X$ es la variable aleatoria condicional Y dado X .

Desvío Estándar

$$\text{SD}(X) = \sigma = \sqrt{\text{Var}(X)} \implies \sigma^2 = \text{Var}(X)$$

Covarianza

$$\text{Cov}(X, Y) = \text{E}[XY] - \text{E}[X] \text{E}[Y]$$

Correlación

$$\rho_{xy} = \frac{\text{cov}_{xy}}{\sigma_x \sigma_y} = \frac{\text{cov}_{xy}}{\text{SD}(x) \text{SD}(y)}$$

Continuas

$$\begin{aligned} F_x(x) &= \int_{-\infty}^x f_X(u) du \\ f_X(x) &= \frac{d}{dx} F_x(x) \end{aligned}$$

$$P(a < X < b) = \int_a^b f(x) dx = F_x(b) - F_x(a)$$

$$P(a < X < b) = P(a < X \leq b) = P(a \leq X < b) = P(a \leq X \leq b)$$

Distribución Normal

Si $X \sim N(\mu, \sigma^2)$ y $a, b \in \mathbb{R}$, entonces $aX + b \sim N(a\mu + b, a^2\sigma^2)$

Si $X \sim N(\mu, \sigma^2)$, entonces $Z = \frac{X - \mu}{\sigma}$ es una variable aleatoria normal estándar: $Z \sim N(0, 1)$.

$$X \sim N(\mu, \sigma^2) \implies Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$Z \sim N(0, 1) \implies X = \sigma Z + \mu \sim N(\mu, \sigma^2)$$

$$X \sim N(\mu, \sigma^2)$$

$$X + b \sim N(\mu + b, \sigma^2)$$

$$aX \sim N(a \times \mu, a^2 \times \sigma^2)$$

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$\bar{X}_n \sim N(\mu, \sigma^2/n), \text{ si } X_i \text{ son i.i.d}$$

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \text{ si } X_i \text{ son i.i.d}$$

Función acumulada

$$f(x) = \phi(x) = \frac{1}{\sqrt{2 \times \pi \times \sigma^2}} \times e^{-\frac{(x-\mu)^2}{2 \times \sigma^2}}$$

Distribución Uniforme

$$P(a < X < b) = \frac{1}{b-a}$$

$$E(X) = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

Distribución Exponencial

$$f_X(X) = \lambda e^{-\lambda X}, \text{ para } X \geq 0$$

$$F_X(x) = P(X > x) = 1 - e^{-\lambda x}$$

$$E(X) = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Discretas

Distribución Bernoulli

$$P(X = 1) = p$$

$$P(X = 0) = 1 - p$$

$$E(X) = p$$

$$\text{Var}(X) = p(1 - p)$$

Distribución Binomial

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$E(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

Distribución Poisson

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

$$E(X) = \lambda$$

$$\text{Var}(X) = \lambda$$

Convergencia en Probabilidad

Sean X_n una secuencia de variables aleatorias, $X_n \xrightarrow{p} X$ si $\forall \epsilon > 0$

$\lim_{n \rightarrow \infty} P(|\bar{X}_n - E(X)| > \epsilon) = 0$, por Ley de los Grandes Números.

Propiedades

Si $X_n \xrightarrow{p} a$ y $Y_n \xrightarrow{p} b$, entonces:

- $X_n + Y_n \xrightarrow{p} a + b$
- $X_n Y_n \xrightarrow{p} a \cdot b$
- $\frac{X_n}{Y_n} \xrightarrow{p} \frac{a}{b}$ si $b \neq 0$
- $g(X_n) \xrightarrow{p} g(a)$ si g es una función continua

Estimación por LGN

Sean X_1, X_2, \dots, X_n variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con esperanza μ y varianza σ^2 . Entonces, la media muestral $\bar{X}_n \xrightarrow{p} \mu$ por LGN. El estimador $\hat{\mu}_n = \bar{X}_n$ es consistente.

Estimación Esperanza

parámetro de interés: $\mu = E(X)$

muestra aleatoria: $X_1, \dots, X_n \sim f$, i.i.d

estimador: $\hat{\mu}_n = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

estimador consistente: $\hat{\mu}_n = \bar{X}_n \xrightarrow{p} \mu$

Estimación Varianza

parámetro de interés: $\sigma^2 = \text{Var}(X)$

muestra aleatoria: $X_1, \dots, X_n \sim f$, i.i.d

estimador: $\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

estimador: $\hat{s}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Estimación Proporción

parámetro de interés: $p = P(X = 1)$

muestra aleatoria: $X_1, \dots, X_n \sim f$, i.i.d

estimador: $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$

estimador consistente: $\bar{X}_n \xrightarrow{p} p$, por LGN

Estimación de Probabilidad

parámetro de interés: $p = F(x) = P(X \leq x)$

muestra aleatoria: $X_1, \dots, X_n \sim f$, i.i.d

definimos $Y_i \sim \text{Bernoulli}(p)$

$Y_i = X_i \leq x = \{1 \text{ si } X_i \leq x, 0 \text{ si } X_i > x\}$

estimador: $\hat{F}_n(x) = \bar{Y}_n = \frac{1}{n} \sum_{i=1}^n 1_{X_i \leq x}$

estimador consistente: $\hat{F}_n(x) = \bar{Y}_n \xrightarrow{p} F(x)$

Formulas Consistencia

Sesgo

$$\text{Sesgo}(\hat{\theta}_n) = E(\hat{\theta}_n) - \theta$$

Si $\text{Sesgo}(\hat{\theta}_n) = 0 \implies E(\hat{\theta}_n) = \theta$

entonces $\hat{\theta}_n$ es insesgado.

Asintóticamente Insesgado

$$\text{Sesgo}(\hat{\theta}_n) = E(\hat{\theta}_n) - \theta \xrightarrow{p} 0$$

Error Estándar

$$SE(\hat{\theta}_n) = \sqrt{\text{Var}(\hat{\theta}_n)}$$

$$\text{Var}(\hat{\theta}_n) = \text{E}[(\hat{\theta}_n - \text{E}(\hat{\theta}_n))^2]$$

Error Cuadrático Medio

$$\text{ECME}(\hat{\theta}_n) = \text{Sesgo}(\hat{\theta}_n)^2 + \text{Var}(\hat{\theta}_n)$$

$$\text{ECME}(\hat{\theta}_n) = \text{E}[(\hat{\theta}_n - \theta)^2]$$

Desigualdad de Chebyshev

$$\text{P}(|X - \mu| \geq \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}$$

Desigualdad de Markov

$$\text{P}(X > \epsilon) \leq \frac{\text{E}(X)}{\epsilon}$$

Momentos

Momentos de una variable aleatoria

Discreta

$$m_k = \text{E}(X^k) = \sum_{i=1}^n (x_i - \bar{x})^k$$

Continua

$$m_k = \int_{\mathbb{R}} x^k f(x) dx$$

$$\text{E}(X) = \mu$$

$$\text{E}(X^2) = \mu^2 + \sigma^2$$

$$\text{E}(X^3) = \mu^3 + 3\mu\sigma^2$$

$$\text{E}(X^4) = \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4$$

Estimación por Máxima Verosimilitud (Likelihood)

$$\mathcal{L}(\theta; \underline{X}) = \prod_{i=1}^n f(\theta; x_i)$$

Log-likelihood

$$l(\theta; \underline{X}) = \ln(\mathcal{L}(\theta; \underline{X})) = \sum_{i=1}^n \ln(f(\theta; x_i))$$

$$\frac{dl(\theta; \underline{X})}{d\theta} = \frac{d \ln(\mathcal{L}(\theta; \underline{X}))}{d\theta} = \sum_{i=1}^n \frac{d \ln(f(\theta; x_i))}{d\theta} = 0$$

Intervalos de Confianza

Intervalo de Confianza para μ

Sea la Variable Aleatoria $X_i \sim N(\mu, \sigma^2)$, nuestro parámetro de interés es μ .

$$\bar{X}_n \sim N(\mu, \sigma^2/n).$$

Si σ^2 es conocido, entonces \bar{X}_n es insesgado y su varianza es σ^2/n .

$$\text{Sea } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \quad \hat{\mu}_n = \bar{X}_n$$

El intervalo de confianza $1 - \alpha$ es:

$$P(-z \leq Z \leq z) = 1 - \alpha$$

$$\phi(z) = P(Z \leq z) = 1 - \alpha/2$$

$$P(-z_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}) = 1 - \alpha$$

$$P(\hat{\mu}_n - z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}} \leq \mu \leq \hat{\mu}_n + z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}) = 1 - \alpha$$

$$\text{IC} = (\hat{\mu}_n - z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}, \hat{\mu}_n + z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}})$$

$$\bar{X}_n \pm z_{\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}$$

T-Student

Si σ^2 es desconocido, entonces \bar{X}_n es insesgado y su varianza es s^2/n

$$\text{Sea } T = \frac{\bar{X}_n - \mu}{\sqrt{\frac{s^2}{n}}} = \frac{\bar{X}_n - \mu}{s/\sqrt{n}} \sim t_{n-1}, \quad \hat{\mu}_n = \bar{X}_n$$

El intervalo de confianza $1 - \alpha$ es:

$$P(-t_{n-1, \alpha/2} \leq T \leq t_{n-1, \alpha/2}) = 1 - \alpha$$

$$P(\hat{\mu}_n - t_{n-1, \alpha/2} \sqrt{\frac{s^2}{n}} \leq \mu \leq \hat{\mu}_n + t_{n-1, \alpha/2} \sqrt{\frac{s^2}{n}}) = 1 - \alpha$$

$$P(\hat{\mu}_n - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \leq \mu \leq \hat{\mu}_n + t_{n-1, \alpha/2} \frac{s}{\sqrt{n}}) = 1 - \alpha$$

$$\text{IC} = (\hat{\mu}_n - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}}, \hat{\mu}_n + t_{n-1, \alpha/2} \frac{s}{\sqrt{n}})$$

$$\bar{X}_n \pm t_{n-1, \alpha/2} \frac{s}{\sqrt{n}}$$